Memoria de Prácticas

Introducción al Aprendizaje Automático

Jesús Fernández López
Rafael Carlos Schoettel Vilchez

Abril, 2026

Cuaderno de Laboratorio — Práctica 4: Clasificación y el Valor del Error (Matriz de Costes)

Objetivo

Entrenar un clasificador probabilístico para un problema de detección de fraude bancario y estudiar cómo el umbral de decisión afecta a los errores cometidos y al coste total. El objetivo central no es únicamente medir el rendimiento predictivo, sino comprender el impacto económico real de las decisiones del modelo a partir de una **matriz de costes asimétrica**.

Descripción del problema

Se trabaja con un problema de clasificación binaria sobre el dataset `fraude_transacciones.cs`

- **Clase 0**: transacción normal.
- **Clase 1**: transacción fraudulenta.

Los errores tienen costes muy distintos:

- **Falso Negativo (FN)**: no detectar un fraude → 200 €
- **Falso Positivo (FP)**: bloquear una transacción legítima → 10 €

La decisión final no debe evaluarse solo por el número de aciertos, sino por el **coste económico** asociado a los errores.

1.1. Tarea 1 — Análisis con el umbral por defecto ($\tau = 0{,}5$)

1.1.1. Modelo utilizado

Se ha entrenado una **Regresión Logística** (`LogisticRegression`, `max_iter=1000`) sobre el 70 % del dataset (partición estratificada, `random_state=42`) y evaluado sobre el 30 % restante.

1.1.2. Matriz de confusión

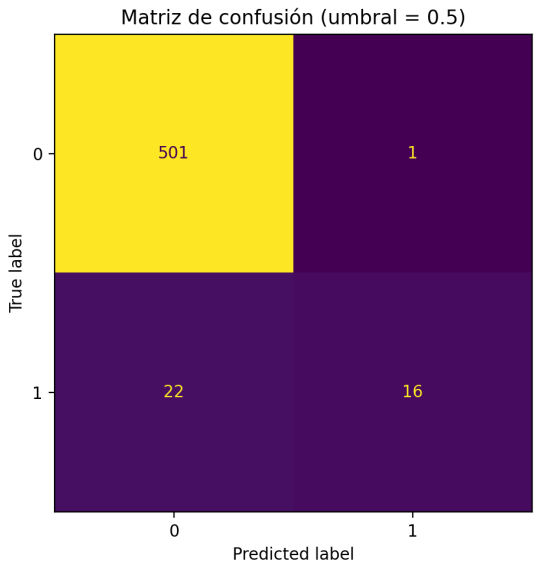

Figura 1.1: Matriz de confusión para el umbral estándar $\tau = 0{,}5$.

A partir de la matriz de confusión detallada en la Figura 1.1, se obtienen los siguientes valores:

- Verdaderos Positivos (TP): **16**
- Verdaderos Negativos (TN): **501**
- Falsos Positivos (FP): **1**
- Falsos Negativos (FN): **22**

1.1.3. Cálculo del coste total

$$\text{Coste Total} = (FP \cdot 10) + (FN \cdot 200) = (1 \cdot 10) + (22 \cdot 200) = \mathbf{4410}\,€$$

1.1.4. Interpretación

El umbral por defecto de 0.5 **no es razonable** en este contexto. Aunque el modelo comete muy pocos falsos positivos (solo 1), deja pasar 22 transacciones

fraudulentas. Dado que el coste de un falso negativo (200 €) es veinte veces el de un falso positivo (10 €), el impacto económico resulta muy elevado. En un sistema de detección de fraude es fundamental minimizar los errores más caros; usar este umbral sin revisarlo sería un error de diseño grave.

1.2. Tarea 2 — Estudio de probabilidades y umbrales

1.2.1. Análisis de distintos umbrales

Se han extraído las probabilidades de la clase fraude para cada observación y se han evaluado umbrales $\tau \in [0, 1]$ en pasos de 0.05. La Tabla 1.1 resume los resultados para los primeros tramos y el extremo superior.

Tabla 1.1: Resumen de FP, FN y Coste Total para distintos umbrales de decisión.

Umbral	FP	FN	Coste Total (€)
0.00	502	0	5020
0.05	112	9	**2920**
0.10	42	14	3220
0.15	22	15	3220
0.20	13	15	3130
0.25	9	16	3290
0.30	4	17	3440
0.40	1	20	4010
0.50	1	22	4410
1.00	0	38	7600

1.2.2. Observaciones

Existe un claro compromiso (*trade-off*) entre los dos tipos de error al variar τ:

- **Cuando el umbral baja** (hacia 0): se exige menos confianza para clasificar como fraude. Caen los Falsos Negativos (detectamos más fraudes), pero aumentan drásticamente los Falsos Positivos (bloqueamos más transacciones legítimas).
- **Cuando el umbral sube** (hacia 1): las alertas son mucho más selectivas. Los Falsos Positivos desaparecen, pero los Falsos Negativos se disparan (dejamos escapar la mayoría de los fraudes).

El umbral de decisión debe ajustarse según la penalización económica de cada error, en lugar de asumir un valor estático por defecto.

Desde una perspectiva de ingeniería, disponer de las probabilidades en crudo (por ejemplo, un 0.30 de probabilidad de fraude) nos otorga un control total sobre la lógica de negocio.

Como ingeniero, ante la asimetría de costes mencionada (donde perder 200 € por un fraude no detectado duele mucho más que los 10 € de un bloqueo erróneo), se puede decidir de forma proactiva: "No voy a esperar a que el modelo esté un 50 % seguro para actuar; voy a bloquear cualquier transacción que supere el 20 % de probabilidad". Al bajar el umbral a $\tau = 0{,}20$, esa transacción con un 0.30 de probabilidad ahora es clasificada correctamente como fraude, permitiendo su bloqueo a tiempo.

En definitiva, al extraer las probabilidades es el diseñador del sistema quien decide dónde situar la línea de corte para equilibrar las pérdidas económicas entre Falsos Positivos (10 €) y Falsos Negativos (200 €), optimizando el sistema para el impacto real en el negocio.

1.3. Tarea 3 — Optimización del coste

1.3.1. Gráfica de coste frente a umbral

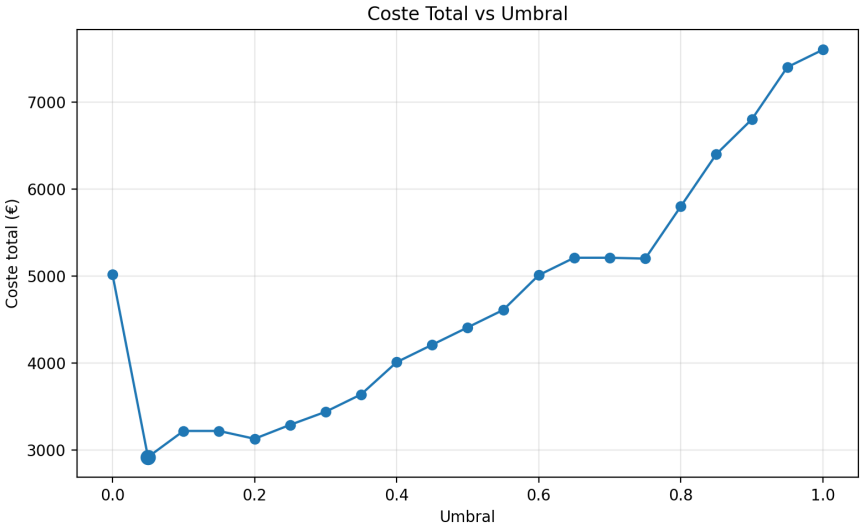

Figura 1.2: Coste total (€) en función del umbral de decisión. Como se aprecia en la Figura 1.2, el punto óptimo se alcanza en $\tau^* = 0{,}05$.

1.3.2. Umbral óptimo

En base a la gráfica anterior, identificamos el punto de menor coste:

$$\tau^* = 0{,}05 \qquad \text{Coste mínimo} = 2920\,€$$

1.3.3. Interpretación

El umbral óptimo ($\tau^* = 0{,}05$) es muy inferior a 0.5. Esto tiene todo el sentido dada la fuerte asimetría de la matriz de costes: el coste de un FN (200 €) es 20 veces el de un FP (10 €). Para minimizar el coste total conviene ser muy sensible a los fraudes, aunque eso suponga aceptar más falsos positivos. La estrategia más razonable para el banco es **conservadora**: es preferible molestar puntualmente a un cliente legítimo mediante un bloqueo temporal que permitir que un fraude se consume sin ser detectado.

1.4. Tarea 4 — Curvas ROC y Precision-Recall

1.4.1. Curva ROC

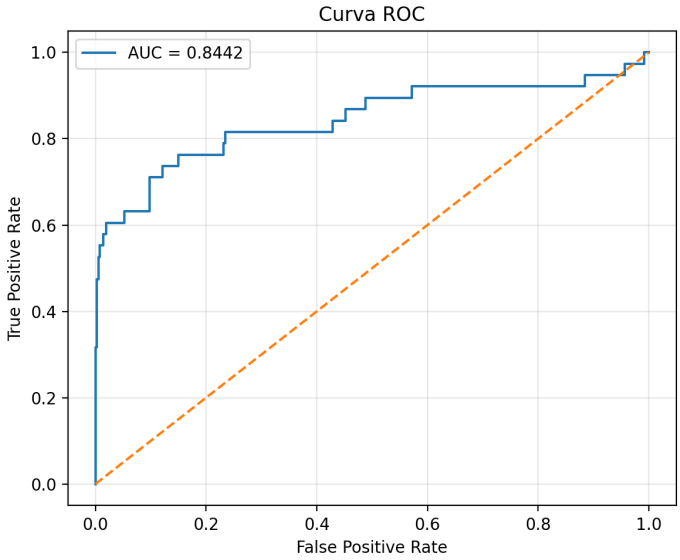

Figura 1.3: Curva ROC del clasificador. AUC-ROC = 0,8442.

1.4.2. Curva Precision-Recall

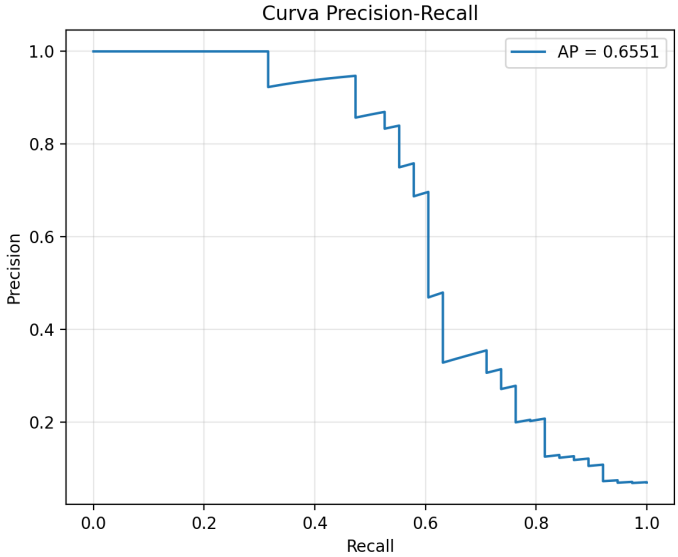

Figura 1.4: Curva Precision-Recall del clasificador. Average Precision = 0,6551.

1.4.3. Discusión

Al analizar un clasificador sobre un dataset desbalanceado, la curva Precision-Recall suele ser mucho más informativa que la ROC (Figura 1.3 frente a Figura 1.4). El motivo es estructural: el *False Positive Rate* de la curva ROC toma como denominador el total de negativos, que en este problema es muy numeroso. Como consecuencia, incrementos apreciables de falsos positivos apenas desplazan el FPR y el AUC-ROC se mantiene elevado (0.8442) pese a que el modelo comete errores relevantes sobre la clase fraude. La curva PR evita este efecto porque la Precisión (TP / (TP + FP)) cae en cuanto aumentan los FP, lo que la hace sensible exactamente a la calidad de recuperación de la clase minoritaria que interesa controlar.

1.5. Decisión final de ingeniería

A la vista de los resultados, se propone fijar $\tau = 0{,}05$ en lugar del umbral por defecto. Con este valor el coste total desciende de 4410 € a 2920 € sobre el conjunto de prueba, una reducción del 34 %. El incremento en falsos positivos (de 1 a 112) es considerable, pero su coste unitario (10 €) es veinte veces inferior al de un falso negativo (200 €), de modo que la operación resulta económicamente ventajosa: se

pasa de 22 FN a 9 FN, y el ahorro por fraudes detectados supera con amplitud el coste adicional por bloqueos erróneos.

Cabe señalar que este umbral se ha determinado exclusivamente a partir de la función de coste definida en la práctica. En un entorno real debería validarse sobre datos de producción y recalibrarse periódicamente si la distribución de transacciones varía.

1.6. Conclusión final

La práctica pone de manifiesto que la elección del umbral de decisión no es una cuestión trivial: fijar $\tau = 0{,}5$ sin análisis previo generó un coste de 4410 €, frente a los 2920 € obtenidos con el umbral óptimo. Hemos verificado que el valor que minimiza el coste total se desplaza hacia la izquierda respecto al punto de equilibrio porque la penalización por FN (200 €) es desproporcionadamente mayor que la de FP (10 €): a medida que se baja el umbral, el ahorro por fraudes adicionales detectados supera el coste extra de los bloqueos erróneos, hasta que ambos efectos se igualan en torno a $\tau^* = 0{,}05$.

Asimismo, se comprueba que en problemas con clases fuertemente desbalanceadas el AUC-ROC puede inducir a conclusiones optimistas, mientras que la curva Precision-Recall refleja con mayor fidelidad la capacidad del modelo para recuperar la clase minoritaria sin disparar el número de falsas alarmas. Ambos resultados subrayan que la evaluación de un clasificador en producción debe incorporar necesariamente los costes asociados al dominio y no limitarse a métricas genéricas.