Práctica 2: Selección de Modelos y Regularización

Objetivo: Dominar el protocolo de Validación Cruzada (K-Fold) y comprender cómo la regularización Lasso y Ridge previenen el sobreajuste y ayudan a la selección de atributos.

Material de partida

Se proporciona el script `seleccion_modelos_viviendas.py` (o `.jl`) que contiene:

- Un dataset sintético de 200 viviendas con 10 variables predictoras.
- Implementación de la validación cruzada y del cálculo del RMSE (raíz del error cuadrático medio).

Tarea 1: Estabilidad de la Validación Cruzada (K-Fold)

Utilizando una regresión lineal estándar (sin regularización), realiza los siguientes experimentos variando el número de folds (K):

- $K = 2$ **(Validación simple):** Ejecuta el modelo varias veces.
- **Análisis:** ¿Por qué el error varía tanto entre una ejecución y otra? ¿Es fiable esta métrica para tomar una decisión técnica?
- $K = 10$ **(el estándar):** Observa el valor del RMSE.
- $K = 100$ **(Leave-One-Out):**
- **Análisis:** Comenta el coste computacional observado frente a $K = 10$. ¿Merece la pena el tiempo extra para mejorar la precisión obtenida?

Tarea 2: Regularización Ridge vs. Lasso

-> Obj: 3 variables, resto es Ruido

En esta sección aprenderemos a "limpiar" el modelo de las variables de ruido. Utiliza $K = 10$ y realiza las siguientes pruebas:

- **Ridge Regression (Penalización L2):** Prueba con $\lambda = 0{,}1$, 10 y 100.
- Observa el gráfico de barras de los coeficientes. ¿Llegan a valer cero los coeficientes de las variables ruidosas (`Var_4` a `Var_10`)?
- **Lasso Regression (Penalización L1):** Prueba con los mismos valores de λ.
- **Análisis:** Identifica para qué valor de λ el modelo Lasso consigue "eliminar" (poner a cero) las 7 variables ruidosas, quedándose solo con las 3 importantes.
- **El dilema de la complejidad:** Explica qué ocurre con el error (RMSE) si aplicas un λ demasiado alto (ej. 1000). ¿Estamos ante un caso de sesgo alto o varianza alta?

Reto: El "Cazador de Variables"

codificar tema del tiempo

Imagina que cada variable que incluyes en tu modelo tiene un coste de mantenimiento.
Tu objetivo es encontrar el modelo más sencillo posible (menos variables con coeficientes distintos de cero) que mantenga un RMSE inferior a un umbral establecido por el profesor.

- Justifica tu elección: Indica qué valor de λ has elegido y qué variables ha mantenido el modelo.

Formato de Entrega

Debes entregar un Informe de Resultados (PDF) que responda a los puntos anteriores e incluya:

- Comparativa de RMSE para distintos valores de K.
- Captura del gráfico de barras de los coeficientes para Lasso y Ridge con λ óptimo.
- Conclusión técnica: ¿Por qué para este dataset Lasso es preferible a Ridge? (Pista: Piensa en la naturaleza de las variables de ruido).