Práctica 3: Metodología de Evaluación y Rigor Científico

Objetivo: Aprender a realizar evaluaciones honestas en condiciones difíciles, especialmente con datos desbalanceados, y detectar errores metodológicos graves como la fuga de datos (*data leakage*).

Material de partida

Se proporciona lo siguiente:

- Un dataset sintético de 1000 pacientes, con 5 variables predictoras.
- Un problema de clasificación fuertemente desbalanceado, donde solo el 2 % de los casos pertenecen a la clase positiva (`clase 1`).

Tarea 1: La lotería de la partición aleatoria

Utilizando el dataset desbalanceado proporcionado, realiza una evaluación básica con partición aleatoria:

- Ejecuta `train_test_split` con partición 80/20 en **5 ocasiones distintas**.
- En cada ejecución, registra cuántos ejemplos de la clase positiva (`clase 1`) han quedado en el conjunto de test.
- Analiza si la composición del test cambia mucho entre ejecuciones debido al azar.
- **Pregunta:** ¿Es posible evaluar correctamente un modelo si en el conjunto de test solo aparecen 0 o 1 casos positivos?

Tarea 2: Partición estratificada

Sustituye la estrategia anterior por una partición estratificada para preservar la proporción de clases.

- Aplica `StratifiedKFold`.
- Comprueba la proporción de la clase positiva en cada uno de los folds.
- Demuestra que el porcentaje de la clase 1 se mantiene aproximadamente constante en todas las particiones.
- **Análisis:** Explica por qué esta estrategia es más adecuada cuando el dataset está desbalanceado.

Tarea 3: Comparativa de la varianza

Compara la estabilidad de la evaluación usando validación cruzada normal y validación cruzada estratificada.

- Calcula el rendimiento del modelo mediante métricas como **Accuracy** y **F1**.
- Realiza **10 iteraciones** con validación cruzada estándar (`KFold`) y **10 iteraciones** con validación cruzada estratificada (`StratifiedKFold`).
- Calcula la **desviación típica** de los resultados obtenidos en ambos casos.
- **Conclusión:** Indica qué método produce métricas más estables y menos dependientes del azar.

Tarea 4: Detección de *Data Leakage* (La trampa)

En esta parte se introduce una variable artificial que filtra información del objetivo y puede provocar una evaluación engañosa.

- Entrena un modelo utilizando todas las variables, incluida la variable `trampa`.
- Observa si el resultado obtenido es anormalmente alto (por ejemplo, cercano al 100 %). Hay una puesta a propósito trampa
- Identifica qué variable está provocando la fuga de datos.
- Elimina esa variable y repite el experimento.
- **Reflexión:** Compara el resultado "engañoso" con el resultado más realista tras eliminar la variable problemática.

Reto: Auditoría metodológica

Actúa como si fueras un revisor de un artículo científico o un auditor técnico de un sistema de IA.
Tu objetivo es detectar qué decisiones metodológicas invalidan una evaluación y justificar por qué.

- Explica por qué una partición aleatoria simple puede ser poco fiable en problemas desbalanceados.
- Justifica por qué la validación estratificada mejora el rigor experimental.
- Identifica el efecto del *data leakage* y explica por qué conduce a conclusiones falsas sobre el rendimiento real del modelo.
- Resume qué buenas prácticas metodológicas deberían seguirse en futuros experimentos.

Formato de entrega

Debes entregar un **Informe de Resultados (PDF)** que incluya:

- Una tabla o resumen con el número de casos positivos presentes en el conjunto de test en las 5 ejecuciones de la partición aleatoria.
- Una comprobación de la proporción de clases en los folds generados por `StratifiedKFold`.
- Una comparativa de métricas (`Accuracy` y/o `F1`) entre validación cruzada normal y estratificada.
- El cálculo de la desviación típica en ambos casos.
- Una explicación clara del caso de *data leakage*, indicando cuál es la variable problemática y cómo cambia el resultado al eliminarla.
- Una conclusión final sobre la importancia del rigor metodológico en problemas de clasificación desbalanceada.