Práctica 4: Clasificación y el Valor del Error (Matriz de Costes)

Objetivo: Entrenar un clasificador probabilístico sencillo para un problema de detección de fraude y analizar cómo el umbral de decisión afecta a los errores y al coste total. En particular, se pretende comprender que no todos los errores tienen el mismo valor y que la matriz de costes permite tomar decisiones más realistas que el uso automático del umbral estándar de clasificación.

Material de partida

Se proporciona lo siguiente:

- Un dataset sintético de detección de transacciones fraudulentas.
- Un problema de clasificación binaria:
  - clase 0: transacción normal;
  - clase 1: transacción fraudulenta.
- Un escenario en el que los errores de clasificación tienen costes muy distintos:
  - un **Falso Negativo** (no detectar un fraude) cuesta **200€**;
  - un **Falso Positivo** (bloquear incorrectamente una transacción legítima) cuesta **10€**.

Nota

En esta práctica se proporcionará una plantilla de código base para facilitar la carga de datos, la partición entrenamiento/prueba y el entrenamiento inicial del modelo. El trabajo del alumno consistirá en completar el análisis, estudiar el efecto del umbral y justificar la decisión final a partir de los resultados obtenidos.

Introducción

En muchos problemas reales de clasificación no basta con medir cuántos aciertos comete un modelo. En contextos como la detección de fraude, un error puede ser mucho más grave que otro. No detectar una operación fraudulenta puede suponer una pérdida económica elevada, mientras que bloquear una operación legítima puede ser molesto o costoso, pero normalmente menos grave.
Esto significa que la decisión final no debe tomarse únicamente a partir de métricas generales como la exactitud, sino teniendo en cuenta el **coste real de los errores**. En esta práctica vas a estudiar cómo cambia el comportamiento de un clasificador al modificar el umbral de decisión y cómo elegir el umbral más adecuado desde un punto de vista de ingeniería.

Tarea 1: El umbral por defecto (0.5)

En esta primera parte trabajarás con el umbral estándar que utilizan muchos clasificadores binarios: clasificar como positiva toda observación cuya probabilidad estimada sea al menos 0.5.

Qué debes hacer

- Entrena una **Regresión Logística** con el dataset proporcionado.
- Evalúa el modelo sobre el conjunto de prueba.
- Obtén las predicciones usando el umbral estándar de 0.5.
- Calcula la **Matriz de Confusión**.
- Identifica cuántos:
  - Verdaderos Positivos,
  - Verdaderos Negativos,
  - Falsos Positivos,
  - Falsos Negativos

  aparecen en el resultado.

Cuestión

Calcula el **coste total** para el banco usando la siguiente regla:

$$\text{Coste Total} = (FP \cdot 10) + (FN \cdot 200)$$

Debes sustituir en la fórmula los valores obtenidos en tu matriz de confusión y explicar el resultado.

Reflexión

Comenta si el umbral por defecto de 0.5 parece razonable en este contexto. No respondas solo mirando si el modelo acierta mucho o poco: debes tener en cuenta si los errores más caros están siendo correctamente controlados.

Tarea 2: Probabilidades y umbrales

En lugar de quedarte con la clase predicha directamente, en esta parte vas a trabajar con las **probabilidades estimadas** por el modelo para la clase positiva.

Qué debes hacer

- Extrae, para cada observación, la probabilidad de pertenecer a la clase `fraude`.
- Evalúa distintos valores del umbral de decisión τ entre 0 y 1, en pasos de 0.05.
- Para cada umbral:
  - genera nuevas predicciones;
  - calcula la matriz de confusión;
  - registra el número de **Falsos Positivos** y **Falsos Negativos**.

Pista: al bajar el umbral suelen aumentar los positivos detectados, lo que normalmente reduce falsos negativos pero incrementa falsos positivos.

Qué debes observar

Analiza cómo cambian los errores al mover el umbral:

- cuando el umbral baja, ¿qué suele pasar con los Falsos Positivos?;
- cuando el umbral sube, ¿qué suele pasar con los Falsos Negativos?;
- ¿qué tipo de compromiso aparece entre ambos tipos de error?

Interpretación

Debes explicar por qué el umbral de clasificación no es una constante sagrada, sino una decisión de diseño que depende del contexto del problema.

Tarea 3: Optimización del coste

En esta parte vas a transformar el problema de clasificación en un problema de decisión económica.

Qué debes hacer

- Para cada umbral considerado en la tarea anterior, calcula el coste total usando:

$$\text{Coste Total} = (FP \cdot 10) + (FN \cdot 200)$$

- Guarda el coste obtenido para cada valor del umbral.
- Representa una gráfica con:
  - eje X: umbral;
  - eje Y: coste total en euros.

Análisis

A partir de la gráfica:

- identifica el **umbral óptimo según la matriz de costes**, es decir, el que minimiza el coste total definido en esta práctica;
- indica si ese umbral es mayor o menor que 0.5;
- explica por qué ese valor tiene sentido en este problema concreto.

Decisión de ingeniería

Debes justificar qué política sería más adecuada para el banco:

- una política conservadora, que detecte más posibles fraudes aunque bloquee algunas transacciones legítimas;
- o una política más permisiva, que reduzca bloqueos erróneos pero deje escapar más fraudes.

La respuesta debe basarse en la matriz de costes, no solo en intuiciones generales.

Tarea 4: Curvas ROC y Precision-Recall

Ahora vas a estudiar dos herramientas habituales para evaluar clasificadores probabilísticos.

Qué debes hacer

- Representa la **curva ROC** de tu modelo.
- Representa la **curva Precision-Recall**.
- Calcula, si lo consideras oportuno, métricas resumen como el área bajo la curva.

Análisis

Debes responder a la siguiente cuestión:
¿Si el dataset está desbalanceado, ¿cuál de las dos curvas refleja mejor la utilidad real del modelo para el departamento de seguridad?
Tu respuesta debe estar razonada. No basta con definir ambas curvas: debes explicar cuál es más informativa en este problema y por qué.

Pista conceptual

Recuerda que en datasets desbalanceados puede ocurrir que un modelo parezca razonable en una curva general, pero resulte poco útil cuando se analiza con más atención su capacidad para recuperar la clase minoritaria sin disparar falsos avisos.

Reto: Diseñar una política de decisión

Imagina que formas parte del equipo técnico del banco y debes recomendar una regla de clasificación que se utilizará en producción.
Debes redactar una breve propuesta respondiendo a estas preguntas:

- ¿Usarías el umbral 0.5 por defecto o lo cambiarías?
- ¿Qué umbral recomendarías finalmente?
- ¿En qué te basas para justificar esa decisión?
- ¿Qué consecuencias prácticas tendría esa elección para el banco y para los clientes?

En esta parte se valorará especialmente tu capacidad para conectar los resultados numéricos con una decisión realista y argumentada.

Formato de entrega

Debes entregar un **Informe de Resultados (PDF)** que incluya:

- la matriz de confusión obtenida con el umbral por defecto de 0.5;
- el cálculo del coste total asociado a ese umbral;
- una tabla o resumen con los valores de FP, FN y coste total para varios umbrales analizados;
- una gráfica de **Coste Total vs. Umbral**;
- la identificación y justificación del umbral óptimo;
- la curva ROC y la curva Precision-Recall;
- una discusión final sobre cuál de ambas curvas es más útil en este problema;
- una conclusión donde se explique por qué en clasificación no todos los errores valen lo mismo.

Recomendaciones

A la hora de redactar el informe, evita limitarte a pegar resultados numéricos. Debes interpretar lo que ocurre en cada fase:

- qué implica usar el umbral estándar;
- por qué cambiar el umbral modifica la relación entre falsos positivos y falsos negativos;
- cómo se traduce esa relación en pérdidas económicas;
- por qué una evaluación útil debe incorporar el contexto del problema.
- el informe debe ser claro y sintético. No es necesario incluir capturas de código extensas; deben priorizarse los resultados y su interpretación.

El objetivo final de esta práctica es que entiendas que un modelo de clasificación no debe evaluarse solo por su capacidad predictiva abstracta, sino también por el impacto real de sus decisiones.