Práctica 5: Arquitectura de Redes Neuronales (Perceptrón Multicapa, MLP)

Objetivo: Comprender cómo la arquitectura de una red neuronal afecta a su capacidad de representación y generalización. En particular, se estudiará por qué un modelo lineal falla en problemas no lineales, cómo influye el número de neuronas y capas ocultas en la frontera de decisión, y qué papel juegan las funciones de activación en el aprendizaje de un Perceptrón Multicapa.

Material de partida

Se proporciona lo siguiente:

- Un conjunto de datos sintético no lineal, como `make_moons`, en el que las clases no pueden separarse mediante una única recta.
- Un segundo conjunto de datos basado en dígitos escritos a mano (versión simplificada de MNIST), que permitirá estudiar redes más profundas en un problema más realista.
- Una plantilla de código base en Python con `scikit-learn`, para facilitar la generación de datos, el entrenamiento inicial de modelos y la representación gráfica de resultados.

Nota

En esta práctica se proporcionará una implementación base para acelerar el trabajo mecánico. El objetivo no es que construyas una red neuronal desde cero, sino que analices de forma razonada cómo cambian los resultados al modificar la arquitectura del modelo.

Introducción

En prácticas anteriores has trabajado con modelos lineales o con clasificadores cuya capacidad de decisión era relativamente limitada. Sin embargo, muchos problemas reales presentan fronteras entre clases que no pueden representarse mediante una línea recta o un hiperplano simple.
Las redes neuronales permiten superar esta limitación mediante la combinación de capas y funciones de activación no lineales. Gracias a ello, un **Perceptrón Multicapa (MLP)** puede aprender regiones de decisión más complejas y adaptarse a problemas donde los modelos lineales fracasan.
Pero esta mayor flexibilidad también introduce nuevas preguntas de ingeniería:

- ¿Cuántas capas ocultas hacen falta?
- ¿Cuántas neuronas conviene usar?
- ¿Qué función de activación resulta más adecuada?
- ¿Cuándo un modelo empieza a ajustarse demasiado a los datos y pierde capacidad de generalización?

En esta práctica vas a explorar estas cuestiones de forma experimental, observando cómo cambia el comportamiento del modelo al modificar su arquitectura.

Tarea 1: El problema de la no linealidad

En esta primera parte trabajarás con un conjunto de datos no lineal, por ejemplo con forma de lunas o círculos concéntricos.

Qué debes hacer

- Genera o carga un dataset no lineal de clasificación binaria.
- Entrena un **Perceptrón simple**, es decir, un modelo sin capas ocultas.
- Evalúa su rendimiento sobre los datos.
- Representa gráficamente:
  - los puntos del dataset;
  - la frontera de decisión aprendida por el modelo.

Cuestión

Debes explicar por qué este modelo falla en este problema.
No basta con indicar que el resultado es malo: debes relacionarlo con la naturaleza del modelo. En particular, debes razonar por qué una combinación lineal de las variables de entrada no es suficiente para separar correctamente las clases.

Reflexión

Comenta qué relación existe entre:

- la forma geométrica de los datos;
- la forma de la frontera de decisión;
- y la capacidad expresiva del modelo.

El objetivo de esta parte es que entiendas que el fallo no se debe simplemente a una mala ejecución, sino a una limitación estructural del modelo.

Tarea 2: Diseñando la capa oculta

Una vez comprobado que el perceptrón simple no basta, vas a añadir una capa oculta al modelo.

Qué debes hacer

- Entrena varios MLP con **una sola capa oculta**.
- Prueba al menos las siguientes configuraciones:
  - 2 neuronas;
  - 5 neuronas;
  - 20 neuronas.
- Para cada configuración:
  - entrena el modelo;
  - evalúa su rendimiento;
  - representa la frontera de decisión resultante.

Qué debes observar

Analiza cómo cambia la frontera de decisión al aumentar el número de neuronas ocultas:

- con pocas neuronas, ¿la frontera sigue siendo demasiado simple?;
- al aumentar el número de neuronas, ¿el modelo capta mejor la estructura no lineal?;
- ¿aparece algún caso en que la frontera se vuelve excesivamente irregular o demasiado adaptada a los datos?

Análisis

Debes discutir la relación entre la complejidad del modelo y su comportamiento:

- un modelo demasiado simple puede producir **underfitting**;
- un modelo demasiado flexible puede empezar a producir **overfitting**.

Tu explicación debe apoyarse en las gráficas y en los resultados observados, no solo en definiciones teóricas.

Tarea 3: Funciones de activación

En esta parte estudiarás cómo influye la función de activación de las capas ocultas.

Qué debes hacer

- Elige una arquitectura fija de MLP.
- Entrénala dos veces:
  - una usando **Sigmoide**;
  - otra usando **ReLU**.
- Compara ambos modelos en términos de:
  - evolución del entrenamiento;
  - número de iteraciones necesarias para converger;
  - rendimiento final;
  - aspecto de la frontera de decisión.

Cuestiones

Debes responder razonadamente a estas preguntas:

- ¿Cuál de las dos funciones parece converger más rápido?
- ¿Se observan diferencias en la estabilidad del entrenamiento?
- ¿La frontera de decisión resultante parece más suave o más abrupta en algún caso?

Interpretación

No se trata solo de decir cuál funciona mejor en tu experimento, sino de explicar por qué puede ocurrir. Puedes relacionarlo con ideas como:

- la saturación de la sigmoide;
- la facilidad de optimización;
- la capacidad de introducir no linealidad;
- y el efecto práctico sobre el aprendizaje.

Tarea 4: El reto de la caja negra

Ahora trabajarás con un problema más realista: clasificación de dígitos escritos a mano.

Qué debes hacer

- Carga el dataset proporcionado de dígitos.
- Diseña distintas arquitecturas MLP variando:
  - el número de capas ocultas;
  - el número de neuronas por capa.
- Debes encontrar una configuración que alcance al menos un **95 % de acierto**.

Restricción experimental

No se trata de probar combinaciones al azar sin criterio. Debes justificar el proceso seguido:

- qué arquitecturas has probado;
- cuáles han funcionado peor o mejor;
- y cuál consideras la configuración mínima razonable para alcanzar el objetivo.

Reflexión

Debes discutir la siguiente cuestión:
¿Es preferible una sola capa con muchas neuronas o dos capas con menos neuronas cada una?

Tu respuesta debe ir más allá de una afirmación general. Debes apoyarte en los resultados obtenidos y discutir el compromiso entre:

- simplicidad;
- capacidad de representación;
- dificultad de entrenamiento;
- interpretabilidad del diseño;
- y rendimiento alcanzado.

Reto: Tomar una decisión de diseño

Imagina que formas parte de un equipo técnico que necesita desplegar un clasificador basado en redes neuronales para un problema real.
Debes redactar una breve propuesta respondiendo a estas preguntas:

- ¿Cuándo tiene sentido usar una red sin capas ocultas y cuándo no?
- ¿Qué arquitectura recomendarías para un problema no lineal sencillo?
- ¿Qué ventajas e inconvenientes observas al aumentar el número de neuronas?
- ¿Qué función de activación elegirías en un problema general de clasificación y por qué?
- ¿Qué criterio usarías para decidir si una arquitectura es suficientemente buena sin hacerla innecesariamente compleja?

En esta parte se valorará especialmente la capacidad de conectar los resultados experimentales con una decisión de diseño razonada.

Formato de entrega

Debes entregar un **Informe de Resultados (PDF)** que incluya:

- una breve explicación del problema de la no linealidad;
- los resultados obtenidos con el perceptrón simple;
- al menos tres experimentos con una capa oculta variando el número de neuronas;
- las gráficas de las fronteras de decisión correspondientes;
- una comparación entre Sigmoide y ReLU;
- los experimentos realizados sobre el dataset de dígitos;
- la arquitectura final seleccionada para alcanzar el objetivo del 95 %;
- una discusión comparando redes más anchas frente a redes más profundas;
- una conclusión final sobre el papel de la arquitectura en el comportamiento de un MLP.

Recomendaciones

A la hora de redactar el informe, evita limitarte a pegar capturas de código o tablas sin explicación. Debes interpretar lo que ocurre en cada fase:

- por qué un modelo lineal falla en datos no lineales;
- cómo las capas ocultas modifican la frontera de decisión;
- por qué más neuronas no siempre implican una mejor solución;
- qué diferencias prácticas introduce la función de activación;
- y cómo justificar una arquitectura desde el punto de vista de la generalización, no solo del acierto bruto.

El informe debe ser claro, sintético y razonado. Deben priorizarse los resultados, las visualizaciones y su interpretación.

Objetivo final de la práctica

El objetivo final de esta práctica es que entiendas que una red neuronal no es una caja mágica que mejora automáticamente cualquier problema, sino una familia de modelos cuyo comportamiento depende de decisiones de diseño concretas: la arquitectura, la función de activación y el equilibrio entre capacidad de ajuste y generalización.