Práctica 7: La Inteligencia Colectiva

Modelos de Ensambles en Aprendizaje Automático

Introducción al Aprendizaje Automático
3º Curso - Ingeniería Informática
Curso 2025/2026

El Problema: Clasificación de Cáncer de Mama

Breast Cancer Wisconsin Dataset

Utilizaremos un dataset real integrado en scikit-learn.

Objetivo: Clasificación binaria (tumor benigno vs. maligno).

Entrada: Múltiples variables predictoras extraídas de imágenes celulares.

Misión de la Práctica

No programaremos desde cero. El objetivo es comprender:

1. Por qué falla un clasificador individual.
2. Cómo cooperan múltiples modelos.
3. Qué información útil se extrae (ej. importancia de variables).

El Árbol Solitario y el Peligro del Overfitting

¿Qué es el Overfitting?

Ocurre cuando un modelo no solo aprende patrones, sino que memoriza el ruido. Pierde su capacidad de generalizar.

El problema de los Árboles

Sin restricciones de profundidad, crean particiones diminutas. Son sensibles al ruido; un cambio mínimo altera toda la estructura.

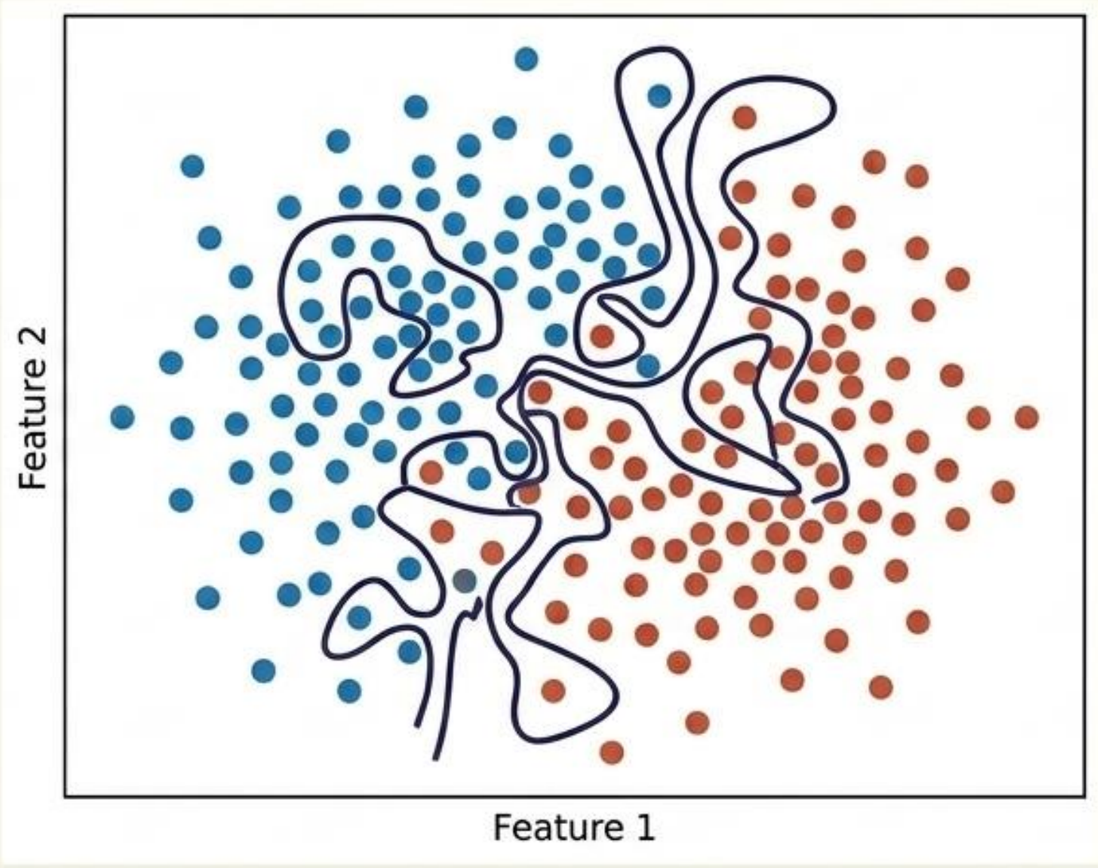

Frontera de decisión de un árbol sobreajustado.

Práctica: Entrenando el Modelo de Referencia

Tarea 1: DecisionTreeClassifier

Entrenamos un árbol simple sin limitar su profundidad. Servirá como línea base.

```
tree = DecisionTreeClassifier()

tree.fit(X_train, y_train)

y_pred = tree.predict(X_test)
```

Resultados Esperados: La trampa

Accuracy en Train: ~ 100% ✅

Accuracy en Test: ~ 92% ⚠️

Claramente inferior

Análisis

Esta brecha es la firma del overfitting. La perfección en entrenamiento indica que el árbol se ha vuelto demasiado rígido, no que sea un buen modelo.

La Intuición: La Sabiduría de las Multitudes

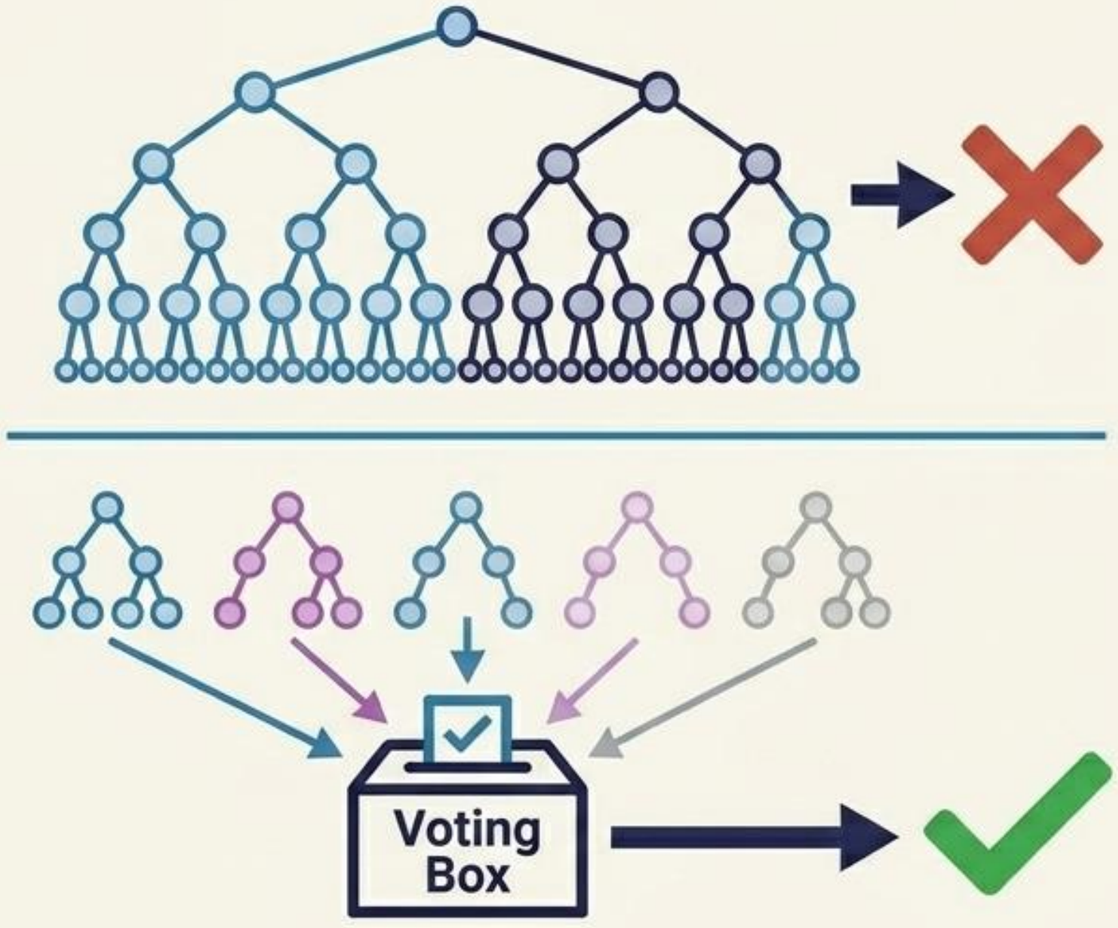

Modelos de Ensamble

En lugar de confiar en una única decisión frágil, combinamos clasificadores que cooperan.

¿Por qué funciona?

- **Diversidad**: Los errores se compensan si los modelos fallan en distintos ejemplos.
- **Estabilidad**: La votación conjunta es robusta frente a datos anómalos.

Random Forest: Bagging y Reducción de Varianza

El concepto de Bagging

Bootstrap Aggregating

1. Múltiples subconjuntos al azar (con reemplazo).
2. Un árbol independiente por subconjunto.
3. Predicción final por votación mayoritaria.

¿Por qué generaliza mejor?

Cada árbol sobreajusta a su propia muestra, pero al promediarlos, la varianza del modelo global se reduce. **Se suavizan las fronteras ruidosas.**

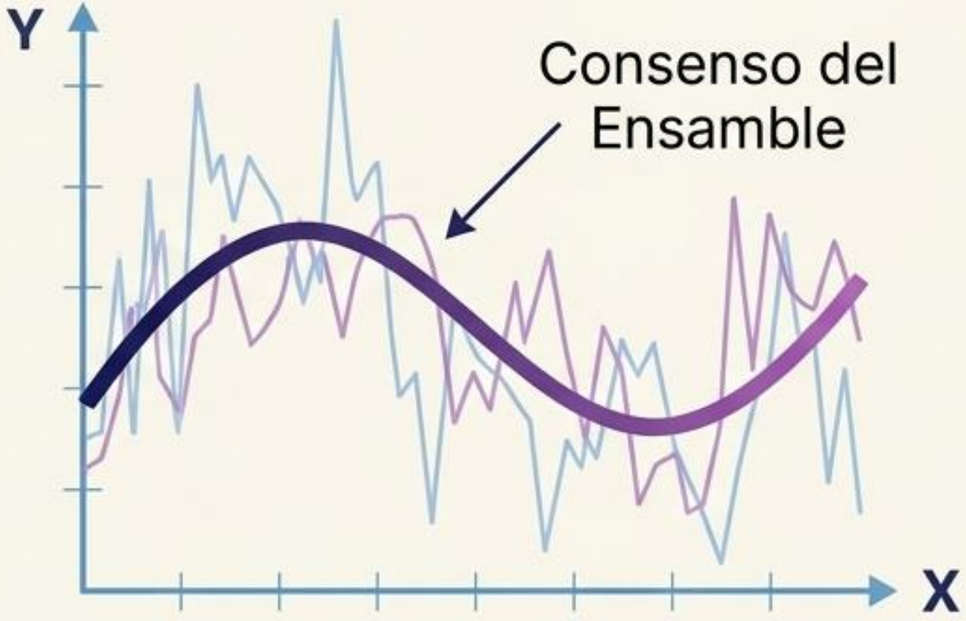

Práctica: Random Forest y la Curva de Saturación

Tarea 2: Variando estimadores (N = 1, 10, 50, 100)

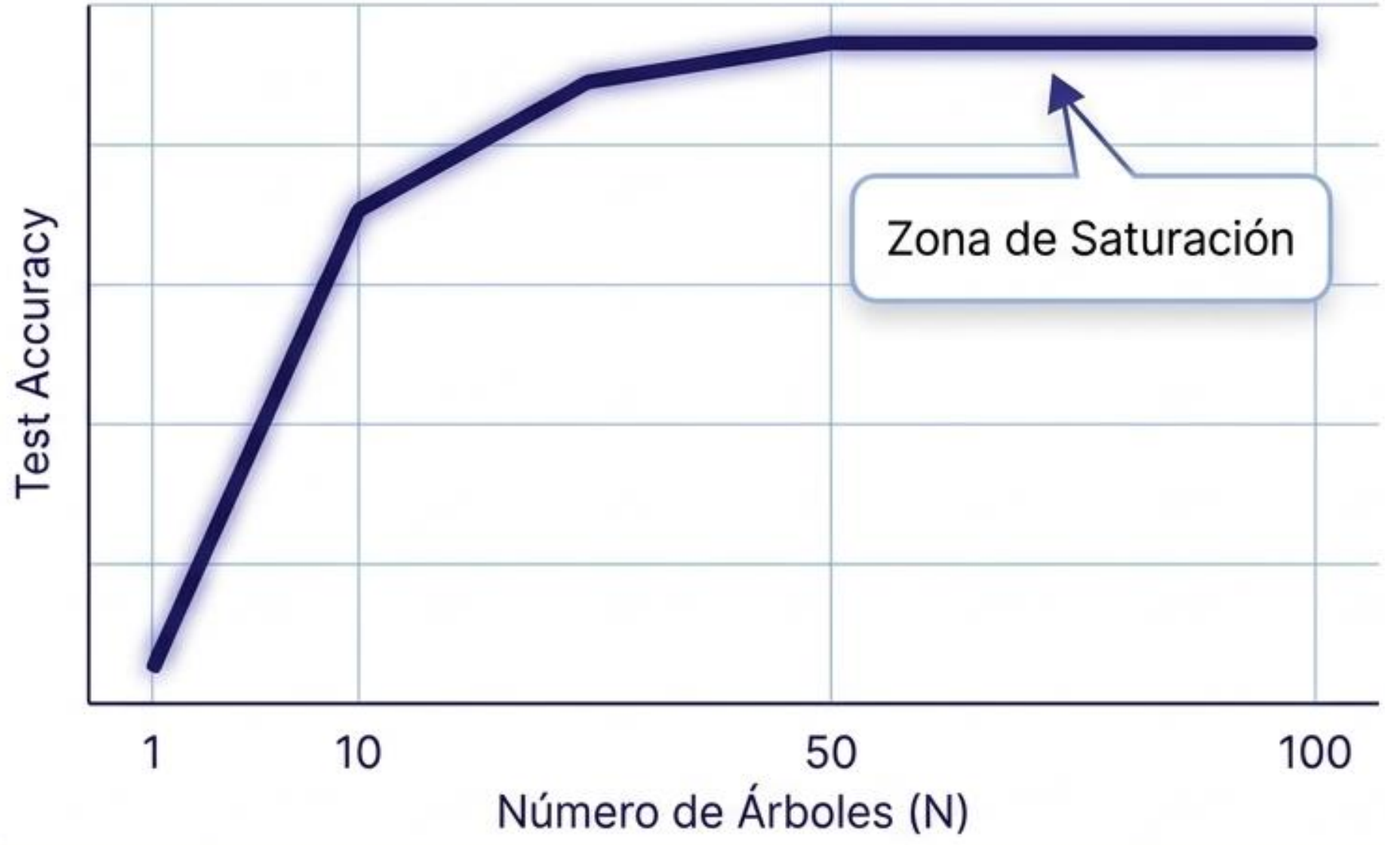

Estabilización

A partir de ~ 50 árboles, la curva se aplana.

¿Por qué deja de mejorar?

Añadir árboles no causa overfitting aquí, pero alcanza un límite. Una vez minimizada la varianza por consenso, añadir un votante extra aporta mejora marginal nula.

El Poder del Boosting: Entrenamiento Secuencial

Un enfoque diferente

Random Forest construye en paralelo.
Boosting construye en serie.

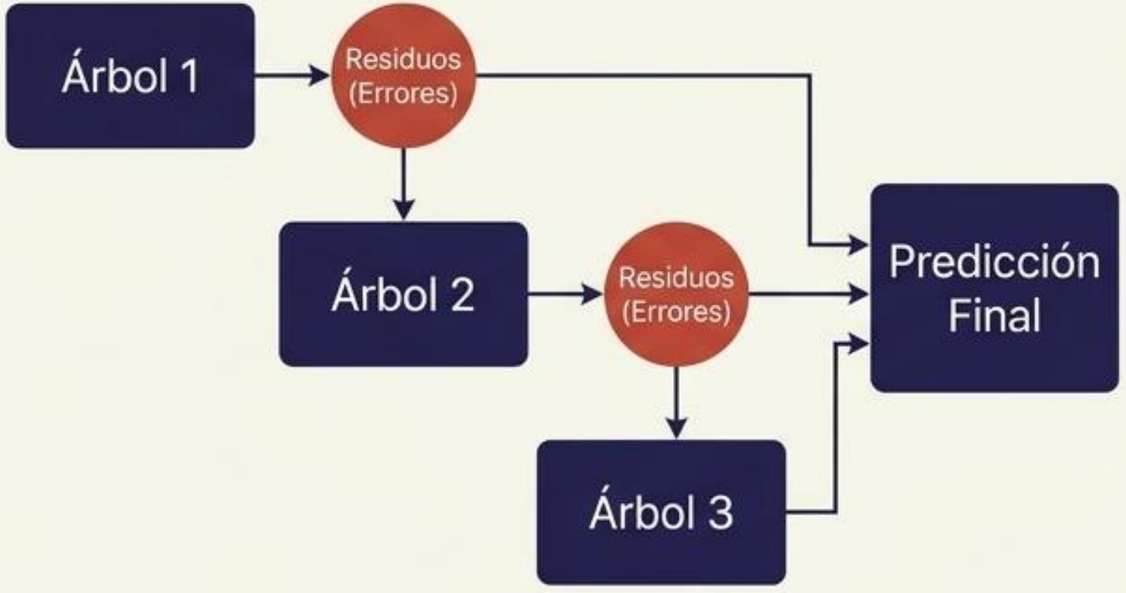

Corrigiendo errores

- Árbol 1 predice.
- Se evalúan los residuos (errores).
- Árbol 2 se entrena solo para corregir esos fallos.
- Proceso guiado y progresivo.

Práctica: Evaluando Boosting y Variables Clave

Coste Computacional

Al ser secuencial, GradientBoostingClassifier no se paraleliza fácilmente. Su tiempo de entrenamiento es mayor que Random Forest.

Feature Importances

El modelo identifica qué variables discriminan mejor:

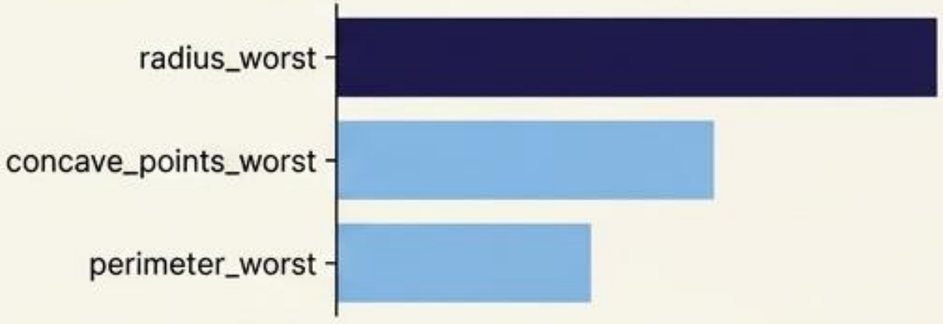

Identifica que la morfología anómala extrema dicta el diagnóstico. No todas las variables valen lo mismo.

Comparativa Intuitiva: Random Forest vs. Boosting

Característica	Random Forest (Bagging)	Boosting
Construcción	En paralelo (independientes)	Secuencial (dependientes)
Objetivo	Reducir la Varianza	Reducir el Sesgo (Error)
Árbol Base	Profundos (sobreajustados)	Muy simples (débiles)
Overfitting	Muy bajo al añadir N	Puede sobreajustar si N es alto

Tarea 4: Comparación Global de Resultados

Resumen Experimental

Métrica	Árbol Simple	Random Forest	Boosting
Train Acc	100.0%	~ 100.0%	~ 99.5%
Test Acc	~ 92.0%	**~ 96.5%**	**~ 97.0%**
Sobreajuste	Alto	Bajo	Medio
Entreno	Muy Bajo	Bajo (Paralelo)	Moderado (Serie)

Reflexión

Los ensambles superan claramente al árbol individual en Test, demostrando empíricamente que agregar decisiones reduce el error de generalización.

El Precio de la Inteligencia Colectiva

Las mejoras no son gratuitas

La capacidad predictiva aumenta, pero introduce nuevos desafíos sistémicos:

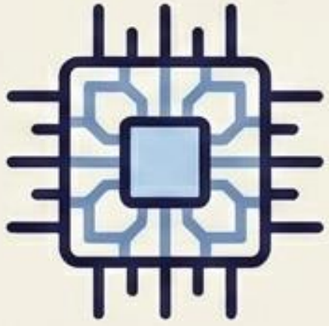

1. Coste Computacional

Entrenar 100 árboles requiere (idealmente) 100 veces más CPU y RAM.

2. Latencia

En inferencia real, predecir exige pasar el dato por el ensamble completo.

3. Caja Negra

Perdemos la interpretabilidad visual directa de un árbol simple.

Conclusiones Clave de la Práctica

¿Qué hemos aprendido?

- **Overfitting:** Un árbol profundo memoriza ruido y falla al generalizar.
- **Random Forest:** Bagging (paralelo) reduce drásticamente la varianza y mejora la estabilidad.
- **Boosting:** Entrenamiento secuencial que fuerza la corrección de errores, reduciendo el sesgo.
- **Trade-off:** La precisión de los ensambles se paga con pérdida de interpretabilidad y mayor coste.

La inteligencia colectiva es una de las ideas más potentes y versátiles del Aprendizaje Automático moderno.