



PRÁCTICA 8: ACTIVE LEARNING (APRENDIZAJE ACTIVO)

Objetivo: Comprender cómo un modelo puede aprender de forma más eficiente cuando no se etiquetan ejemplos al azar, sino que se seleccionan de manera inteligente aquellos datos que resultan más informativos. En particular, se estudiará el enfoque de **Active Learning** o **Aprendizaje Activo**, comparando una estrategia de etiquetado aleatorio frente a una estrategia basada en la **incertidumbre del modelo**. El objetivo final será analizar cómo maximizar el rendimiento de un clasificador cuando el número de etiquetas disponibles es limitado.

Material de partida

Se proporciona lo siguiente:

- Un código base que prepara automáticamente un dataset sintético de clasificación binaria mediante `make_moons`.
- Un conjunto inicial de **10 puntos etiquetados**.
- Un conjunto amplio de puntos no etiquetados, denominado *pool*.
- Un conjunto de test separado para evaluar el rendimiento del modelo.
- El vector de etiquetas reales, que actuará como **oráculo** durante el proceso de consulta.
- Una plantilla con las librerías necesarias para entrenar modelos, calcular probabilidades y representar gráficas.

IMPORTANTE: En esta práctica no tienes que generar el dataset desde cero. El código base ya prepara los datos necesarios. Tu trabajo consiste en implementar y analizar el proceso de **aprendizaje activo**: entrenar con pocas etiquetas, seleccionar nuevos ejemplos informativos, consultar sus etiquetas y comparar esta estrategia frente a una selección aleatoria.

Introducción

En muchos problemas reales de aprendizaje automático, disponer de datos no suele ser el principal problema. Lo difícil, costoso o lento suele ser conseguir datos correctamente etiquetados. Por ejemplo, puede ser relativamente fácil recopilar miles de imágenes, señales o registros, pero etiquetarlos puede requerir la intervención de expertos. En esta práctica simularemos este escenario con un dataset sintético. Aunque conocemos todas las etiquetas verdaderas, el modelo solo podrá acceder inicialmente a **10 etiquetas**. El resto estarán ocultas para el modelo y únicamente se revelarán cuando el algoritmo decida consultar esos puntos.

Una estrategia sencilla sería seleccionar nuevos ejemplos al azar. Sin embargo, esta selección puede ser poco eficiente, ya que algunos ejemplos pueden ser redundantes, muy fáciles o poco informativos. El **Active Learning** propone una idea diferente: dejar que el modelo indique qué ejemplos le resultan más útiles para aprender. Para ello, se seleccionan aquellos puntos sobre los que el modelo tiene mayor incertidumbre.

En esta práctica vas a comparar dos estrategias:

- una estrategia **aleatoria**, que selecciona nuevos ejemplos sin tener en cuenta el estado del modelo;
- una estrategia de **aprendizaje activo por incertidumbre**, que selecciona los ejemplos cuya predicción está más cerca de la duda.

Partiremos de una situación con pocas etiquetas iniciales y un presupuesto máximo de **50 etiquetas**. La pregunta clave será:

¿Es mejor gastar el presupuesto de etiquetas al azar o usarlo en los ejemplos que más pueden ayudar al modelo?

Tarea 1: Entrenamiento inicial

En esta primera parte vas a entrenar un modelo utilizando únicamente los **10 puntos etiquetados iniciales** proporcionados por el código base.

Qué debes hacer

- Utiliza el conjunto inicial de 10 ejemplos etiquetados.
- Entrena un clasificador sobre esos datos iniciales.



PRÁCTICA 8: ACTIVE LEARNING (APRENDIZAJE ACTIVO)

- Puedes utilizar un modelo como `RandomForestClassifier`.
- Evalúa el modelo sobre el conjunto de test separado.
- Calcula y guarda el valor de *accuracy* inicial.

Cuestión

Debes explicar si el rendimiento inicial del modelo te parece fiable.

Ten en cuenta que el modelo se ha entrenado con muy pocos ejemplos. Por tanto, puede haber zonas del espacio de entrada mal representadas o regiones cercanas a la frontera de decisión donde el clasificador todavía no sabe separar correctamente las clases.

Análisis

Comenta qué limitaciones tiene entrenar un modelo con solo 10 ejemplos etiquetados. En particular, reflexiona sobre la poca representatividad del conjunto inicial, la sensibilidad a qué ejemplos concretos han sido elegidos y la dificultad de aprender una frontera de decisión adecuada.

Tarea 2: Estrategia baseline con selección aleatoria

Antes de aplicar Active Learning, necesitas construir una estrategia de referencia. Esta estrategia consistirá en añadir nuevas etiquetas de forma aleatoria hasta alcanzar el presupuesto máximo permitido.

Qué debes hacer

- Parte de los mismos 10 ejemplos etiquetados inicialmente.
- En cada iteración, selecciona aleatoriamente **5 ejemplos** del pool no etiquetado.
- Consulta sus etiquetas reales usando el vector de etiquetas proporcionado.
- Añade esos ejemplos al conjunto de entrenamiento.
- Elimina esos ejemplos del pool no etiquetado.
- Reentrena el modelo y evalúalo sobre el conjunto de test.
- Guarda el número de etiquetas utilizadas y el *accuracy* obtenido.
- Repite el proceso hasta alcanzar un total de **50 etiquetas**.

Cuestión

Debes explicar por qué esta estrategia constituye una línea base razonable.

La selección aleatoria no utiliza información del modelo, pero permite medir qué rendimiento se obtiene simplemente aumentando el número de etiquetas sin aplicar ninguna estrategia inteligente de selección.

Tarea 3: Ciclo de consulta mediante incertidumbre

Ahora vas a implementar la estrategia principal de la práctica: seleccionar los ejemplos que generan mayor incertidumbre en el modelo.

En un problema binario, si el clasificador estima probabilidades de pertenencia a clase, una predicción cercana a 0.5 indica que el modelo duda entre ambas clases. Estos puntos suelen estar cerca de la frontera de decisión y pueden aportar mucha información si se etiquetan.

Qué debes hacer

- Parte de los mismos 10 ejemplos etiquetados inicialmente.
- Entrena el modelo con los ejemplos etiquetados disponibles.
- Calcula las probabilidades predichas sobre el pool no etiquetado.
- Identifica los puntos cuya probabilidad esté más cerca de 0.5.



PRÁCTICA 8: ACTIVE LEARNING (APRENDIZAJE ACTIVO)

- Selecciona los **5 ejemplos más inciertos**.
- Consulta sus etiquetas reales usando el vector de etiquetas proporcionado, que actuará como **oráculo**.
- Añade esos ejemplos al conjunto de entrenamiento y elimínalos del pool no etiquetado.
- Reentrena el modelo, evalúalo en test y guarda el número de etiquetas utilizadas y el *accuracy*.
- Repite el proceso hasta alcanzar un total de **50 etiquetas**.

Código orientativo

Una forma sencilla de seleccionar los ejemplos más inciertos en clasificación binaria es la siguiente:

```
probs = model.predict_proba(X_unlabeled)[: , 1]

uncertainty = np.abs(probs - 0.5)

query_idx = np.argsort(uncertainty)[:5]
```

En este caso, los ejemplos con menor valor de **uncertainty** son aquellos donde el modelo está más cerca de asignar una probabilidad de 0.5, es decir, donde tiene más dudas.

Cuestión

Debes explicar por qué tiene sentido seleccionar los puntos más cercanos a la frontera de decisión. Tu explicación debe relacionar la incertidumbre del modelo con la cantidad de información que puede aportar una nueva etiqueta. Un ejemplo muy fácil puede confirmar algo que el modelo ya sabe. En cambio, un ejemplo dudoso puede ayudar a corregir o ajustar la frontera de decisión.

Tarea 4: Comparativa final mediante curva de aprendizaje

Una vez implementadas ambas estrategias, debes comparar sus resultados mediante una curva de aprendizaje.

Qué debes hacer

- Representa en una misma gráfica la evolución del *accuracy* frente al número de etiquetas utilizadas.
- Incluye la curva correspondiente a la selección aleatoria.
- Incluye la curva correspondiente a la selección por incertidumbre.
- El eje X debe representar el número de etiquetas usadas.
- El eje Y debe representar el rendimiento en test.

Gráfica esperada

La gráfica debe incluir título, nombres de los ejes, leyenda y una escala adecuada para interpretar la evolución del rendimiento.

Nota: La curva de aprendizaje no tiene por qué ser perfectamente creciente. Añadir nuevos ejemplos puede modificar la frontera de decisión y producir pequeñas oscilaciones en el rendimiento. Lo importante es analizar la tendencia general y comparar ambas estrategias bajo el mismo presupuesto de etiquetas.

Cuestión

Debes responder razonadamente a esta pregunta:

¿Qué estrategia obtiene mejor rendimiento con el mismo número de etiquetas?

No se trata únicamente de mirar el último punto de la curva. Debes analizar la tendencia completa: si una estrategia mejora antes, si hay oscilaciones, si ambas acaban pareciéndose o si la estrategia activa aprovecha mejor las primeras consultas.



PRÁCTICA 8: ACTIVE LEARNING (APRENDIZAJE ACTIVO)

Tarea 5: Reflexión sobre la frontera de decisión

En esta última parte debes interpretar por qué la estrategia basada en incertidumbre puede ser más eficiente que la selección aleatoria.

Pregunta de reflexión

Debes responder razonadamente a la siguiente pregunta:

¿Por qué el modelo aprende más rápido cuando elige puntos cercanos a la frontera de decisión?

Interpretación

Tu respuesta debe relacionar, al menos, las siguientes ideas:

- los puntos cercanos a la frontera son más difíciles de clasificar;
- esos puntos suelen generar mayor incertidumbre en el modelo;
- conocer su etiqueta ayuda a ajustar mejor la frontera de decisión;
- los puntos muy alejados de la frontera suelen aportar menos información nueva;
- y una buena estrategia de consulta puede aprovechar mejor un presupuesto limitado de etiquetas.

Análisis crítico

Comenta también alguna posible limitación de esta estrategia. Por ejemplo, puedes discutir qué ocurre si el modelo inicial está mal entrenado, si la incertidumbre estimada por el modelo siempre es fiable o si elegir siempre los puntos más inciertos puede producir una muestra poco representativa.

Reto: Pensando en un problema real

Imagina ahora que cada etiqueta tiene un coste económico. Por ejemplo, cada dato debe ser revisado por una persona experta y solo puedes pagar un número muy reducido de anotaciones.

Qué debes hacer

Debes discutir qué estrategia utilizarías en un escenario real con presupuesto limitado: selección aleatoria, selección por incertidumbre u otra estrategia alternativa que consideres razonable.

Cuestiones

Debes responder razonadamente a estas preguntas:

- ¿Qué estrategia elegirías?
- ¿Qué ventajas tendría respecto a etiquetar ejemplos al azar?
- ¿Qué riesgos o limitaciones podría tener?
- ¿Qué ocurriría si el modelo inicial estuviera muy mal entrenado?
- ¿Puede Active Learning seleccionar ejemplos poco representativos si solo se centra en la incertidumbre?

Interpretación

El objetivo de esta parte es que entiendas que Active Learning no es una solución mágica. Aunque puede reducir el número de etiquetas necesarias, también depende de la calidad del modelo inicial, de la estrategia de consulta y de que los ejemplos seleccionados sean realmente útiles para mejorar la generalización.



PRÁCTICA 8: ACTIVE LEARNING (APRENDIZAJE ACTIVO)

Formato de entrega

Debes entregar un **Informe de Resultados (PDF)** que incluya:

- una breve descripción del problema de aprendizaje activo planteado;
- el rendimiento inicial del modelo entrenado con solo 10 etiquetas;
- la descripción de la estrategia baseline basada en selección aleatoria;
- la descripción de la estrategia de Active Learning basada en incertidumbre;
- la curva de aprendizaje comparando ambas estrategias;
- una interpretación de qué estrategia aprende más rápido y por qué;
- una respuesta razonada a la pregunta sobre los puntos cercanos a la frontera de decisión;
- una reflexión sobre el coste de etiquetado y las limitaciones del aprendizaje activo;
- y una conclusión razonada sobre cuándo usarías Active Learning en un problema real.

Recomendaciones

A la hora de redactar el informe, evita limitarte a copiar gráficas o valores numéricos sin explicarlos. Debes interpretar los resultados y relacionarlos con las ideas teóricas trabajadas en la práctica.

Conviene que prestes especial atención a cuestiones como:

- qué significa que un modelo tenga incertidumbre;
- por qué los puntos cercanos a la frontera de decisión pueden ser especialmente informativos;
- por qué es importante comparar Active Learning frente a una estrategia aleatoria;
- cómo interpretar una curva de aprendizaje;
- qué limitaciones tiene seleccionar únicamente los puntos más inciertos;
- y por qué el coste de etiquetado es un factor clave en muchos problemas reales.

El informe debe ser claro, sintético y razonado. Deben priorizarse los resultados experimentales, las gráficas comparativas y la interpretación de las diferencias entre las estrategias.

Objetivo final de la práctica

El objetivo final de esta práctica es que entiendas que el aprendizaje automático no depende solo del modelo utilizado, sino también de la forma en que se construye el conjunto de entrenamiento. En problemas donde las etiquetas son caras o escasas, seleccionar inteligentemente qué ejemplos etiquetar puede ser tan importante como elegir un buen clasificador.

Al finalizar esta práctica, deberías ser capaz de explicar por qué el **Active Learning** puede aprovechar mejor un presupuesto limitado de etiquetas y qué limitaciones deben tenerse en cuenta al aplicarlo en un problema real.