



PRÁCTICA 9: FEW-SHOT LEARNING APRENDIZAJE CON POCOS EJEMPLOS

Objetivo: Comprender cómo un modelo puede reconocer una clase nueva utilizando muy pocos ejemplos etiquetados. En particular, se estudiará el enfoque de **Few-shot Learning** mediante una versión sencilla de **Redes Prototípicas** aplicada al dataset MNIST. El objetivo final será analizar cómo un modelo entrenado sin ver una clase concreta puede reutilizar su extractor de características para representar esa clase nueva mediante un pequeño conjunto de ejemplos de apoyo.

Material de partida

Se proporciona lo siguiente:

- Un código base que carga automáticamente el dataset MNIST.
- Una división del problema en un **mundo sin sietes**, donde el modelo se entrena inicialmente sin imágenes de la clase 7.
- Una red neuronal sencilla que actúa primero como clasificador y posteriormente como **extractor de características (embedding)**.
- Un **support set** con pocos ejemplos del dígito 7.
- Un **query set** con ejemplos de test para evaluar si el modelo reconoce correctamente la nueva clase.
- Funciones auxiliares para calcular prototipos, distancias euclídeas y precisión.
- Una plantilla con las librerías necesarias para entrenar el modelo, obtener embeddings y representar resultados.

IMPORTANTE: En esta práctica no se trata de entrenar un clasificador convencional con muchas imágenes de todas las clases. El objetivo es simular que aparece una clase nueva, el dígito **7**, de la que solo tenemos muy pocos ejemplos. Tu trabajo consiste en comprobar si el modelo puede reconocer esa clase nueva comparando imágenes en un espacio de características.

Introducción

En muchos problemas reales de aprendizaje automático no siempre se dispone de cientos o miles de ejemplos etiquetados para cada clase. En ocasiones aparece una clase nueva de la que solo tenemos unas pocas muestras: una nueva especie animal, un defecto raro en una cadena de producción, una enfermedad poco frecuente o una categoría visual que el sistema no había visto antes.

Una solución ingenua sería reentrenar el modelo completo con esos pocos ejemplos. Sin embargo, esto suele ser poco fiable: con tan pocos datos, el modelo puede sobreajustarse y no aprender una representación general de la nueva clase. Además, si se reentrena de forma inadecuada, puede empeorar su rendimiento sobre las clases que ya conocía. El **Few-shot Learning** propone una idea distinta: en lugar de aprender una nueva clase desde cero, se intenta aprovechar una representación ya aprendida. En esta práctica, entrenaremos primero una red neuronal con los dígitos de MNIST excepto el 7. Después eliminaremos su última capa y usaremos la red como **extractor de características**. De esta forma, cada imagen se convertirá en un vector numérico o **embedding**.

A partir de unos pocos ejemplos del número 7, calcularemos un **prototipo**: el vector medio de sus embeddings. Para clasificar nuevas imágenes, calcularemos qué prototipo queda más cerca en el espacio de características.

La pregunta clave será:

¿Puede un modelo reconocer una clase nueva usando solo 1 o 5 ejemplos?

Conceptos clave

En esta práctica se utilizarán tres ideas fundamentales:

- **Support set:** pequeño conjunto de ejemplos etiquetados que se usa para definir una clase nueva.
- **Query set:** conjunto de ejemplos que se desea clasificar después de construir los prototipos.
- **Prototipo:** representación media de una clase en el espacio de embeddings.

Para una clase k , su prototipo se calcula como:

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f(x_i)$$



PRÁCTICA 9: FEW-SHOT LEARNING APRENDIZAJE CON POCOS EJEMPLOS

Donde S_k es el conjunto de apoyo de la clase k y $f(x_i)$ es el embedding producido por el extractor de características. Una imagen de consulta se clasifica asignándola a la clase cuyo prototipo esté más cerca:

$$\hat{y} = \arg \min_k d(f(x), c_k)$$

En esta práctica utilizaremos distancia euclídea.

Tarea 1: Preparación del mundo sin sietes

En esta primera parte vas a preparar el escenario base de la práctica: un modelo que aprende a reconocer los dígitos de MNIST, pero sin haber visto nunca imágenes del número 7 durante el entrenamiento.

Qué debes hacer

- Carga el dataset MNIST.
- Normaliza las imágenes para que los valores estén en el rango $[0, 1]$.
- Separa las imágenes del dígito 7 del conjunto de entrenamiento.
- Entrena una red neuronal sencilla usando únicamente las clases 0, 1, 2, 3, 4, 5, 6, 8 y 9.
- Evalúa el clasificador sobre las clases conocidas.
- Guarda el modelo entrenado.

Cuestión

Explica por qué tiene sentido eliminar la clase 7 durante el entrenamiento inicial.

Tarea 2: Construcción del extractor de características

Una vez entrenado el clasificador inicial, vas a convertirlo en un extractor de características. Para ello, se elimina la última capa de clasificación y se utiliza la salida de una capa intermedia como embedding de cada imagen.

Qué debes hacer

- Toma el modelo entrenado en la tarea anterior.
- Identifica una capa intermedia adecuada para usarla como representación de la imagen.
- Construye un nuevo modelo que reciba una imagen y devuelva su embedding.
- Obtén embeddings para algunas imágenes de ejemplo.
- Comprueba la dimensión del vector generado.

Cuestión

Explica por qué no usamos directamente los píxeles de la imagen para calcular las distancias.

Tarea 3: Cálculo del prototipo del número 7

Ahora aparece la clase nueva: el número 7. El modelo no la ha visto durante el entrenamiento, pero dispones de unos pocos ejemplos etiquetados que actuarán como support set.

Qué debes hacer

- Selecciona 1 imagen del número 7 para construir un prototipo **1-shot**.
- Selecciona 5 imágenes del número 7 para construir un prototipo **5-shot**.
- Pasa esas imágenes por el extractor de características.
- Calcula el vector medio de los embeddings seleccionados.
- Guarda ambos prototipos.



PRÁCTICA 9: FEW-SHOT LEARNING APRENDIZAJE CON POCOS EJEMPLOS

Código orientativo

```
embeddings_support = feature_extractor.predict(X_support)
prototype = np.mean(embeddings_support, axis=0)
```

Cuestión

Explica qué representa el prototipo de una clase, en cada uno de los casos.

Tarea 4: Clasificación por distancia

En esta tarea vas a clasificar imágenes de consulta comparando sus embeddings con los prototipos disponibles.

Qué debes hacer

- Construye prototipos para varias clases conocidas usando pocos ejemplos por clase.
- Añade también el prototipo del número 7.
- Selecciona un query set con imágenes de test.
- Obtén el embedding de cada imagen de consulta.
- Calcula la distancia euclídea entre cada query y cada prototipo.
- Asigna a cada query la clase del prototipo más cercano.
- Calcula la precisión obtenida.

Código orientativo

```
distances = np.linalg.norm(
    query_embeddings[:, None, :] - prototypes[None, :, :],
    axis=2
)

predicted_labels = prototype_labels[np.argmin(distances, axis=1)]
```

Cuestión

Explica por qué clasificar por distancia puede funcionar en un espacio de embeddings.

Tarea 5: Comparación entre 1-shot y 5-shot

En esta parte compararás el rendimiento cuando se dispone de un único ejemplo de apoyo frente a cuando se dispone de cinco ejemplos.

Qué debes hacer

- Ejecuta la clasificación usando prototipos contruidos con 1 ejemplo por clase.
- Ejecuta la clasificación usando prototipos contruidos con 5 ejemplos por clase.
- Evalúa ambos casos sobre el mismo query set.
- Guarda la accuracy de cada configuración.
- Representa una gráfica de barras comparando 1-shot y 5-shot.

Cuestión

Debes responder razonadamente:

¿Mejora el rendimiento al pasar de 1-shot a 5-shot? ¿Por qué?



PRÁCTICA 9: FEW-SHOT LEARNING APRENDIZAJE CON POCOS EJEMPLOS

Tarea 6: Visualización del espacio de características

Para interpretar mejor el comportamiento del sistema, vas a visualizar los embeddings en dos dimensiones mediante una técnica de reducción de dimensionalidad.

Qué debes hacer

- Obtén embeddings de un subconjunto de imágenes de test.
- Aplica PCA o t-SNE para proyectarlos a dos dimensiones.
- Representa los puntos coloreados por clase.
- Marca, si es posible, la posición de los prototipos.
- Observa si el número 7 queda cerca o lejos de otros dígitos.

Cuestión

Explica qué aporta esta visualización para entender el método.

Reto: Pensando en un problema real

Imagina que trabajas en una aplicación de reconocimiento visual y aparece una nueva categoría para la que solo tienes unas pocas imágenes etiquetadas.

Qué debes hacer

Debes discutir cómo aplicarías el enfoque de Few-shot Learning en ese escenario real.

Cuestiones

Responde razonadamente a las siguientes preguntas:

- ¿Qué ventajas tendría usar un extractor de características preentrenado?
- ¿Qué riesgos existen si los pocos ejemplos del support set no son representativos?
- ¿Qué ocurriría si el extractor no genera buenos embeddings para la nueva clase?
- ¿Por qué el enfoque 5-shot puede ser más robusto que el enfoque 1-shot?
- ¿En qué tipo de problemas reales podría ser útil esta estrategia?

Interpretación

El objetivo de esta parte es entender que Few-shot Learning no consiste simplemente en entrenar con pocos datos. La clave está en reutilizar una representación aprendida previamente y clasificar nuevas clases mediante comparación en un espacio de características.

Formato de entrega

Debes entregar un **Informe de Resultados (PDF)** que incluya:

- una breve descripción del problema de Few-shot Learning planteado;
- una explicación del escenario del **mundo sin sietes**;
- la descripción del extractor de características utilizado;
- el cálculo del prototipo del número 7;
- la explicación del proceso de clasificación por distancia;
- una tabla comparando los resultados 1-shot y 5-shot;
- una gráfica comparativa de rendimiento;
- una visualización del espacio de embeddings, si se ha realizado;



PRÁCTICA 9: FEW-SHOT LEARNING APRENDIZAJE CON POCOS EJEMPLOS

- una interpretación de los resultados obtenidos;
- una reflexión sobre las limitaciones del enfoque;
- y una conclusión razonada sobre cuándo usarías Few-shot Learning en un problema real.

Recomendaciones

A la hora de redactar el informe, evita limitarte a copiar valores numéricos sin explicarlos. Debes interpretar los resultados y relacionarlos con las ideas teóricas trabajadas en la práctica.

Conviene prestar especial atención a cuestiones como:

- qué significa aprender con pocos ejemplos;
- qué diferencia hay entre entrenamiento supervisado convencional y Few-shot Learning;
- qué es un support set y qué es un query set;
- qué representa un prototipo;
- por qué se clasifican las imágenes por distancia;
- por qué 5 ejemplos pueden ser mejores que 1;
- y qué limitaciones tiene depender de un extractor de características previamente entrenado.

El informe debe ser claro, sintético y razonado. Deben priorizarse los resultados experimentales, las gráficas comparativas y la interpretación de las diferencias entre 1-shot y 5-shot.

Objetivo final de la práctica

El objetivo final de esta práctica es que entiendas que un modelo puede adaptarse a nuevas clases sin necesidad de reentrenarse completamente desde cero. En problemas donde solo existen unos pocos ejemplos etiquetados, el aprendizaje por prototipos permite reutilizar representaciones previas y clasificar nuevas muestras mediante comparación.

Al finalizar esta práctica, deberías ser capaz de explicar qué es el **Few-shot Learning**, cómo se construye un prototipo, cómo se clasifica una imagen por distancia en un espacio de embeddings y por qué el número de ejemplos de apoyo influye en la robustez del sistema.